Resultados de Mutation Testing

Este relatório consolida os resultados de mutation testing obtidos com PIT para dois contextos experimentais do repositório:

1. o caso controlado `dataloader.MathOperations`;
2. as execuções multi-projeto sobre o benchmark SF110.

1. Snapshot histórico em `MathOperations`

O snapshot agregado original comparou várias suites de testes contra o mesmo conjunto histórico de 102 mutações relevantes.

Test Suite	Tests Run	Killed	Survived	No Coverage	Total	Mutation Score (%)
ALL_COMBINED	229	96	6	0	102	**94.12**
AdvancedValidationTests	17	82	13	7	102	**80.39**
MathOperationsTests	47	82	6	14	102	**80.39**
ExampleTests	38	81	14	7	102	**79.41**
TestDataLoaderEvoSuiteTests	8	80	15	7	102	**78.43**
RobustTests	38	79	14	9	102	**77.45**
AdvancedTests	20	76	17	9	102	**74.51**
ExtendedTests	49	76	17	9	102	**74.51**
MathOperationsEvoSuiteTests	12	75	12	15	102	**73.53**

Leitura principal: a combinação de suites (`ALL_COMBINED`) atingiu o melhor score agregado, mas o desempenho individual variou bastante consoante o alinhamento entre a suite e o código mutado.

2. Rerun focado após melhorias em `MathOperations`

Depois do reforço de testes e da refatoração do alvo, foi executado um rerun PIT focado apenas em `dataloader.MathOperations`.

Run	Tests Run	Killed	Survived	No Coverage	Total	Mutation Score (%)	Test Strength (%)	Line Coverage (%)
MATHOPERATIONS_FOCUSED_AFTER_FIXES	80	71	0	2	73	**97.26**	**100.00**	**97.00**

Observações:

- Todos os mutantes `SURVIVED` foram eliminados neste rerun focado.
- Permaneceram apenas 2 mutações `NO_COVERAGE`, ambas associadas às lambdas sintéticas introduzidas pelos `orElseThrow` em `max()` e `min()`.
- Este resultado não é diretamente comparável ao snapshot histórico de 102 mutações, porque o rerun focado gerou um conjunto diferente de mutações relevantes (`73`).

3. Resultados SF110

Foram executadas quatro campanhas PIT sobre o benchmark SF110. A campanha mais abrangente é `sf110_full_both1`, a única a cobrir todos os 111 projetos SF110 (79 concluídos).

Run	Test Mode	Passed / Executed	Weighted Score (%)	Avg. Score (%)	Avg. Test Strength (%)	Killed / Relevant
sf110_evosuite_smoke_20260426	evosuite	3 / 5	10.38	19.82	—	3485 / 33566
sf110_evosuite_fix1	evosuite	13 / 14	20.64	23.06	—	1429 / 6924
sf110_full_both1	**both**	**79 / 111**	**18.76**	**24.27**	**62.05**	13799 / 73556
sf110_both_smoke_retest_20260502_jdk21	both	1 / 1	40.52	83.97		393 / 970

4. Resultados por projeto — `sf110_full_both1` (modo `both`, 79 projetos)

Esta é a campanha mais completa. Top 10 projetos por mutation score decrescente:

#	Projeto	Score (%)	Test Strength (%)	Killed	Survived	No Coverage	Total
1	`90_dcparseargs`	**90.32**	90.32	84	9	0	93
2	`31_xisemele`	**90.24**	91.64	296	27	5	328
3	`24_saxpath`	**84.09**	87.68	370	52	18	440
4	`26_jipa`	**75.86**	**100.00**	22	0	7	29
5	`40_glengineer`	**67.10**	74.59	414	141	62	617
6	`59_mygrid`	**65.24**	89.84	610	69	256	935
7	`55_lavalamp`	**63.97**	71.49	158	63	26	247
8	`25_jni-inchi`	**62.03**	85.47	147	25	65	237
9	`86_at-robots2-j`	**61.90**	68.29	450	209	68	727
10	`2_a4j`	**54.35**	75.00	225	75	114	414

- `90_dcparseargs` e `31_xisemele` atingiram **>90%** de mutation score — os melhores resultados observados em todo o benchmark SF110.
- `26_jipa` atingiu **100% de test strength**: todos os mutantes cobertos pelos testes foram mortos.
- `59_mygrid` combina score elevado (65.24%) com test strength de 89.84% sobre um projeto de dimensão considerável (935 mutações).

Comparação por projeto — `sf110_full_fix1` (evosuite, 13 projetos)

#	Projeto	Score (%)	Killed	Survived	No Coverage	Total
1	`2_a4j`	**54.35**	225	75	114	414
2	`14_omjstate`	**40.91**	36	14	38	88
3	`13_jdbacl`	**32.51**	354	86	649	1089
4	`7_sfmis`	**31.27**	111	76	168	355
5	`6_jnfe`	**29.18**	82	17	182	281
6	`1_tullibee`	**27.52**	328	46	818	1192
7	`5_templateit`	**22.74**	83	36	246	365
8	`4_rif`	**22.35**	38	43	89	170

#	Projeto	Score (%)	Killed	Survived	No Coverage	Total
9	`3_gaj`	**19.67**	12	14	35	61
10	`11_imsmart`	**6.67**	11	21	133	165
11	`12_dsachat`	**6.10**	75	156	999	1230
12	`10_water-simulator`	**5.05**	73	423	949	1445
13	`9_falselight`	**1.45**	1	2	66	69
—	`8_gfarcegestionfa`	FAIL	—	—	—	—

Caso focal `13_jdbacl` com modo `both`

Projeto	Test Mode	Score (%)	Test Strength (%)	Killed	Survived	No Coverage	Total
`13_jdbacl`	both	**40.52**	**83.97**	393	75	502	970

Combinar EvoSuite com testes manuais subiu o score de 32.51% (evosuite puro) para 40.52% (+8 pp), com test strength de 83.97%.

5. Conclusões para a tese

Os resultados sustentam duas conclusões centrais:

1. No caso controlado `MathOperations`, o mutation score melhora significativamente quando os testes são reforçados e os pontos de mutação equivalente são reduzidos, passando do melhor snapshot agregado (`94.12%`) para `97.26%` no rerun focado.
2. No benchmark SF110, o mutation score reflete não só a qualidade dos testes, mas também a robustez do pipeline experimental. Em campanhas multi-projeto, a taxa de sucesso da execução precisa ser reportada em conjunto com o score agregado.

Para escrita académica, os números mais defensáveis são:

- `94.12%`: snapshot agregado histórico em `MathOperations` com `ALL_COMBINED`.
- `97.26%`: rerun focado pós-melhoria em `MathOperations`.
- `18.76%`: weighted mutation score de `sf110_full_both1` com `79/111` projetos concluídos (campanha mais completa).
- `24.27%`: média por projeto em `sf110_full_both1`.
- `90.32%` / `90.24%`: melhores scores individuais SF110 (`90_dcparseargs` e `31_xisemele`) no modo `both`.
- `40.52%`: caso focal `13_jdbacl` em `both`, com `83.97%` de test strength.

6. Fontes dos dados

- `outputs/mutation_experiments/mutation_results.csv`
- `outputs/mutation_experiments/mathoperations_focused_after_fixes_20260510_summary.json`
- `target/pit-reports/index.html`
- `outputs/mutation_experiments/sf110_full_evosuite_20260426/sf110_mutation_summary.json`
- `outputs/mutation_experiments/sf110_full_fix1/sf110_mutation_summary.json`
- `outputs/mutation_experiments/sf110_full_both1/sf110_mutation_summary.json`
- `outputs/mutation_experiments/sf110_both_smoke_retest_20260510_jdk21/sf110_mutation_summary`