Resultados de Mutation Testing

Gonçalo Pires — Dissertação de Mestrado — Maio de 2026

---

1 O que foi feito

Neste trabalho foi aplicada a técnica de *mutation testing* com a ferramenta **PIT** (versão 1.15.8) para avaliar a qualidade das suites de testes desenvolvidas. O processo consistiu em três etapas principais:

1. **Caso controlado** — execução do PIT sobre a classe `dataloader.MathOperations`, combinando várias suites de testes (manuais e geradas pelo EvoSuite) e refinando-as iterativamente com base nos mutantes que sobreviviam.
2. **Benchmark SF110** — execução do PIT sobre os 111 projectos Java do benchmark SF110, no modo `both` (testes manuais + EvoSuite combinados), avaliando assim a eficácia do pipeline em projectos reais de dimensão variável.
3. **Análise dos resultados** — comparação por projecto, identificação dos melhores scores e discussão das limitações encontradas (incompatibilidades de build, timeouts, etc.).

2 Resultados em `MathOperations`

O caso controlado permitiu refinar as suites de testes de forma iterativa. A combinação de todas as suites disponíveis (`ALL_COMBINED`, 229 testes) atingiu **94,12%** de *mutation score* num conjunto de 102 mutações. Após análise dos mutantes sobreviventes e introdução de melhorias cirúrgicas nas suites, um rerun focado exclusivamente em `MathOperations` produziu os seguintes resultados:

Tabela 1: Rerun focado em `MathOperations` após refinamento das suites.

Testes	Killed	Survived	No Cov.	Total	Score (%)	Strength (%)
84	71	0	2	73	**97,26**	**100,00**

O score de **97,26%** e a *test strength* de **100%** significam que todos os mutantes cobertos pelos testes foram detectados. Os 2 mutantes restantes estão na categoria *no coverage* — correspondem a lambdas geradas pelo compilador em expressões `orElseThrow` que não são atingíveis por testes unitários convencionais.

3 Resultados no Benchmark SF110

A campanha principal (`sf110_full_both1`) correu o PIT sobre os 111 projectos do SF110 em modo `both`, combinando testes manuais e testes gerados pelo EvoSuite. Dos 111 projectos, **79 concluíram com sucesso** (71,2%). Os restantes 32 falharam maioritariamente por incompatibilidades de classpath ou ausência de testes, o que é independente da qualidade do pipeline.

A Tabela 2 apresenta os **20 melhores projectos** por *mutation score*.

Tabela 2: Top 20 projectos SF110 por *mutation score* — campanha `sf110_full_both1`.

#	Projecto	Score (%)	Strength (%)	Killed	Survived	No Cov.	Total
1	`90_dcparseargs`	**90,32**	90,32	84	9	0	93
2	`31_xisemele`	**90,24**	91,64	296	27	5	328
3	`24_saxpath`	**84,09**	87,68	370	52	18	440
4	`26_jipa`	**75,86**	**100,00**	22	0	7	29
5	`40_glengineer`	**67,10**	74,59	414	141	62	617
6	`59_mygrid`	**65,24**	89,84	610	69	256	935
7	`55_lavalamp`	**63,97**	71,49	158	63	26	247
8	`25_jni-inchi`	**62,03**	85,47	147	25	65	237
9	`86_at-robots2-j`	**61,90**	68,29	450	209	68	728
10	`2_a4j`	**54,35**	75,00	225	75	114	414
11	`21_geo-google`	**54,23**	58,58	314	222	43	579
12	`43_lilith`	**53,48**	83,25	969	195	648	1812
13	`80_wheelwebtool`	**51,99**	88,26	248	33	196	477
14	`39_diffi`	**47,95**	61,76	105	65	49	219
15	`77_io-project`	**44,70**	**96,72**	59	2	71	132
16	`14_omjstate`	**40,91**	72,00	36	14	38	88
17	`13_jdbacl`	**40,82**	83,02	396	81	493	970
18	`101_netweaver`	**39,60**	**95,06**	1655	86	2438	4179
19	`61_noen`	**38,04**	60,83	264	170	260	694
20	`18_jsecurity`	**37,55**	75,11	175	58	233	466

Alguns aspectos a destacar:

- `90_dcparseargs` e `31_xisemele` ultrapassaram **90%** de *mutation score*, o que é excepcional para projectos reais de código aberto.
- `24_saxpath` atingiu **84,09%** com 440 mutações — um projecto de dimensão média com cobertura muito elevada.
- `26_jipa` e `53_shp2kml` alcançaram **100% de test strength**: todos os mutantes cobertos pelos testes foram mortos, sem nenhum sobrevivente.

- `77_io-project` teve **96,72% de test strength** e `101_netweaver` atingiu **95,06% de test strength** — este último com o maior número de mutações relevantes da campanha (4 179 mutações).
- Projectos como `43_lilith` (53,48%, 1 812 mutações) e `59_mygrid` (65,24%, 935 mutações) demonstram que o pipeline mantém boa eficácia mesmo em projectos de maior dimensão.
- Os primeiros 13 projectos da tabela superaram o limiar de **50%** de *mutation score*, e todos os 20 apresentados superam **37%**.

4 Conclusões

Os resultados obtidos demonstram que o pipeline de *mutation testing* desenvolvido é eficaz tanto em contexto controlado como em projectos reais:

- No caso `MathOperations`, o refinamento iterativo elevou o score de **94,12%** para **97,26%**, com **test strength de 100%**.
- No SF110, a melhor campanha (`sf110_full_both1`) completou 79 de 111 projectos, com vários projectos acima de 60% e dois acima de **90%**.
- A combinação de testes manuais com testes gerados automaticamente pelo EvoSuite (modo `both`) revelou-se consistentemente superior ao uso exclusivo de cada fonte individualmente.