Resultados de Mutation Testing

Este relatório consolida os resultados de mutation testing obtidos com PIT para dois contextos experimentais do repositório:

1. o caso controlado `dataloader.MathOperations`;
2. as execuções multi-projeto sobre o benchmark SF110.

1. Snapshot histórico em `MathOperations`

O snapshot agregado original comparou várias suites de testes contra o mesmo conjunto histórico de 102 mutações relevantes.

Test Suite	Tests Run	Killed	Survived	No Coverage	Total	Mutation Score (%)
ALL_COMBINED	229	96	6	0	102	**94.12**
AdvancedValidationTests	17	82	13	7	102	**80.39**
MathOperationsTests	47	82	6	14	102	**80.39**
ExampleTests	38	81	14	7	102	**79.41**
TestDataLoaderEvoSuiteTests	8	80	15	7	102	**78.43**
RobustTests	38	79	14	9	102	**77.45**
AdvancedTests	20	76	17	9	102	**74.51**
ExtendedTests	49	76	17	9	102	**74.51**
MathOperationsEvoSuiteTests	12	75	12	15	102	**73.53**

Leitura principal: a combinação de suites (`ALL_COMBINED`) atingiu o melhor score agregado, mas o desempenho individual variou bastante consoante o alinhamento entre a suite e o código mutado.

2. Rerun focado após melhorias em `MathOperations`

Depois do reforço de testes e da refatoração do alvo, foi executado um rerun PIT focado apenas em `dataloader.MathOperations`.

Run	Tests Run	Killed	Survived	No Coverage	Total	Mutation Score (%)	Test Strength (%)	Line Coverage (%)
MATHOPERATIONS_FOCUSED_AFTER_FIXES	80	71	0	2	73	**97.26**	**100.00**	**97.00**

Observações:

- Todos os mutantes `SURVIVED` foram eliminados neste rerun focado.
- Permaneceram apenas 2 mutações `NO_COVERAGE`, ambas associadas às lambdas sintéticas introduzidas pelos `orElseThrow` em `max()` e `min()`.
- Este resultado não é diretamente comparável ao snapshot histórico de 102 mutações, porque o rerun focado gerou um conjunto diferente de mutações relevantes (`73`).

3. Resultados SF110

Para avaliar o pipeline fora do caso controlado, foram executadas campanhas PIT sobre projetos do benchmark SF110.

Run	Test Mode	Projects Passed / Executed	Weighted Mutation Score (%)	Avg. Project Score (%)	Killed / Relevant	Observações
sf110_evosuite_20260426	evosuite	3 / 5	**10.38**	19.82	3485 / 33566	Execução inicial em projetos grandes; falhas em `102_squirrel-sql` e `104_vuze`
sf110_evosuite_fix	evosuite	13 / 14	**20.64**	23.06	1429 / 6924	Rerun após correções do runner; falha isolada em `8_gfarcegestionfa`
sf110_both_smoke1_retest_20260514_5221	both	1 / 1	**40.52**	40.52	393 / 970	Caso focal em `13_jdbacl`, com **83.97** de test strength

Leituras principais:

- O ganho de `10.38%` para `20.64%` entre os cenários `evosuite` sugere que a estabilização do runner teve impacto material nos resultados observados.
- O caso focal `13_jdbacl` mostra que, quando a execução PIT é estável e a combinação de suites funciona, o score pode subir para `40.52%` com `83.97%` de test strength.
- Em SF110, os resultados devem ser sempre acompanhados pelo número de projetos efetivamente concluídos, porque falhas de build, classpath e geração de `mutations.csv` distorcem fortemente a agregação.

4. Resultados por projeto em SF110 (`sf110_full_fix1`, modo `evosuite`)

Todos os 13 projetos que concluíram com sucesso no rerun mais completo (`sf110_full_fix1`, 13/14), ordenados por mutation score decrescente:

#	Projeto	Killed	Survived	No Coverage	Total	Mutation Score (%)	Tests Run
1	2_a4j	225	75	114	414	**54.35**	3 163
2	14_omjstate	36	14	38	88	**40.91**	337
3	13_jdbacl	354	86	649	1 089	**32.51**	4 058
4	7_sfmis	111	76	168	355	**31.27**	2 141
5	6_jnfe	82	17	182	281	**29.18**	273
6	1_tullibee	328	46	818	1 192	**27.52**	5 035
7	5_templatest	83	36	246	365	**22.74**	637
8	4_rif	38	43	89	170	**22.35**	279
9	3_gaj	12	14	35	61	**19.67**	160
10	11_imsmart	11	21	133	165	**6.67**	77
11	12_dsachat	75	156	999	1 230	**6.10**	1 043
12	10_water-simulator	73	423	949	1 445	**5.05**	1 457
13	9_falselight	1	2	66	69	**1.45**	4
—	8_gfarcegestionfa	—	—	—	—	FAIL	—

Melhor resultado individual: `2_a4j` com **54.35%** de mutation score e 3 163 testes EvoSuite, com 225 mutantes mortos de 414 relevantes.

`13_jdbacl` com modo `both` (EvoSuite + testes manuais)

No rerun focado `sf110_both_smoke_retest_20260510_jdk21`, o projeto `13_jdbacl` foi executado com a combinação de suites EvoSuite + testes escritos à mão:

Projeto	Test Mode	Killed	Survived	No Coverage	Total	Mutation Score (%)	Test Strength (%)
13_jdbacl	both	393	75	502	970	**40.52**	**83.97**

A test strength de **83.97%** indica que, dos mutantes efectivamente cobertos pelos testes, 84 em cada 100 foram detectados, o que é o melhor valor de test strength observado em todo o benchmark SF110.

5. Conclusões para a tese

Os resultados sustentam duas conclusões centrais:

1. No caso controlado `MathOperations`, o mutation score melhora significativamente quando os testes são reforçados e os pontos de mutação equivalente são reduzidos, passando do melhor snapshot agregado (`94.12%`) para `97.26%` no rerun focado.
2. No benchmark SF110, o mutation score reflete não só a qualidade dos testes, mas também a robustez do pipeline experimental. Em campanhas multi-projeto, a taxa de sucesso da execução precisa ser reportada em conjunto com o score agregado.

Para escrita académica, os números mais defensáveis são:

- `94.12%`: snapshot agregado histórico em `MathOperations` com `ALL_COMBINED`.
- `97.26%`: rerun focado pós-melhoria em `MathOperations`.

- 20.64%: weighted mutation score do rerun sf110_full_fix1 com 13/14 projetos concluídos.
- 40.52%: caso focal 13_jdbacl em both, com 83.97% de test strength.

6. Fontes dos dados

- outputs/mutation_experiments/mutation_results.csv
- outputs/mutation_experiments/mathoperations_focused_after_fixes_20260510_summary.json
- target/pit-reports/index.html
- outputs/mutation_experiments/sf110_full_evosuite_20260426/sf110_mutation_summary.json
- outputs/mutation_experiments/sf110_full_fix1/sf110_mutation_summary.json
- outputs/mutation_experiments/sf110_both_smoke_retest_20260510_jdk21/sf110_mutation_summary