SF110 + WGAN-Guiado: Resultados

Mutation Testing com seleccao de alvos guiada por aprendizagem WGAN-aware

Objectivo

Avaliar se a seleccao de classes-alvo guiada por um preditor de testabilidade treinado nos perfis estruturais aprendidos pela WGAN melhora o mutation score real medido pelo PIT em projetos do SF110.

Pipeline

1. Recolha de outcomes do PIT em 111 projetos do SF110 (baseline).
2. Extraccao de 15 features estruturais por classe.
3. Construcao do bridge dataset (estrutura -> testabilidade).
4. Treino de RandomForest com validacao leave-projects-out.
5. Geracao de whitelists de classes por projeto via guided_class_selector.
6. Re-execucao do PIT, mas mutando apenas as classes na whitelist.

Anti-bias por construcao

- GroupKFold por projeto: modelo nunca ve o projeto-alvo no treino.
- Features estruturais puras, sem identidade de projeto.
- Validacao multi-seed em todas as comparacoes.

Data: 2026-06-30
Baseline: outputs/mutation_experiments/sf110_full111/
WGAN-guiado: outputs/mutation_experiments/sf110_wgan_guided/

Sumario Executivo

Volumetria

```
Baseline: 111 projetos executados, 67 com sucesso
WGAN-guiado: 111 projetos executados, 80 com sucesso
Projetos comparaveis (passaram nos dois runs): 67
```

Metricas agregadas

```
Weighted score   baseline: 16.73%
Weighted score   WGAN:     45.20%
Weighted strength baseline: 63.25%
Weighted strength WGAN:     73.39%
```

Comparacao em projetos comuns (sem ponderacao)

```
Score medio baseline:    23.18%
Score medio WGAN-guiado: 48.21%  (+25.03pp)
Subiram >0.5pp:    63
Desceram >0.5pp:   0
Ganhos grandes (>=+10pp): 52
Projetos >= 70% (baseline): 4
Projetos >= 70% (WGAN):     14
```

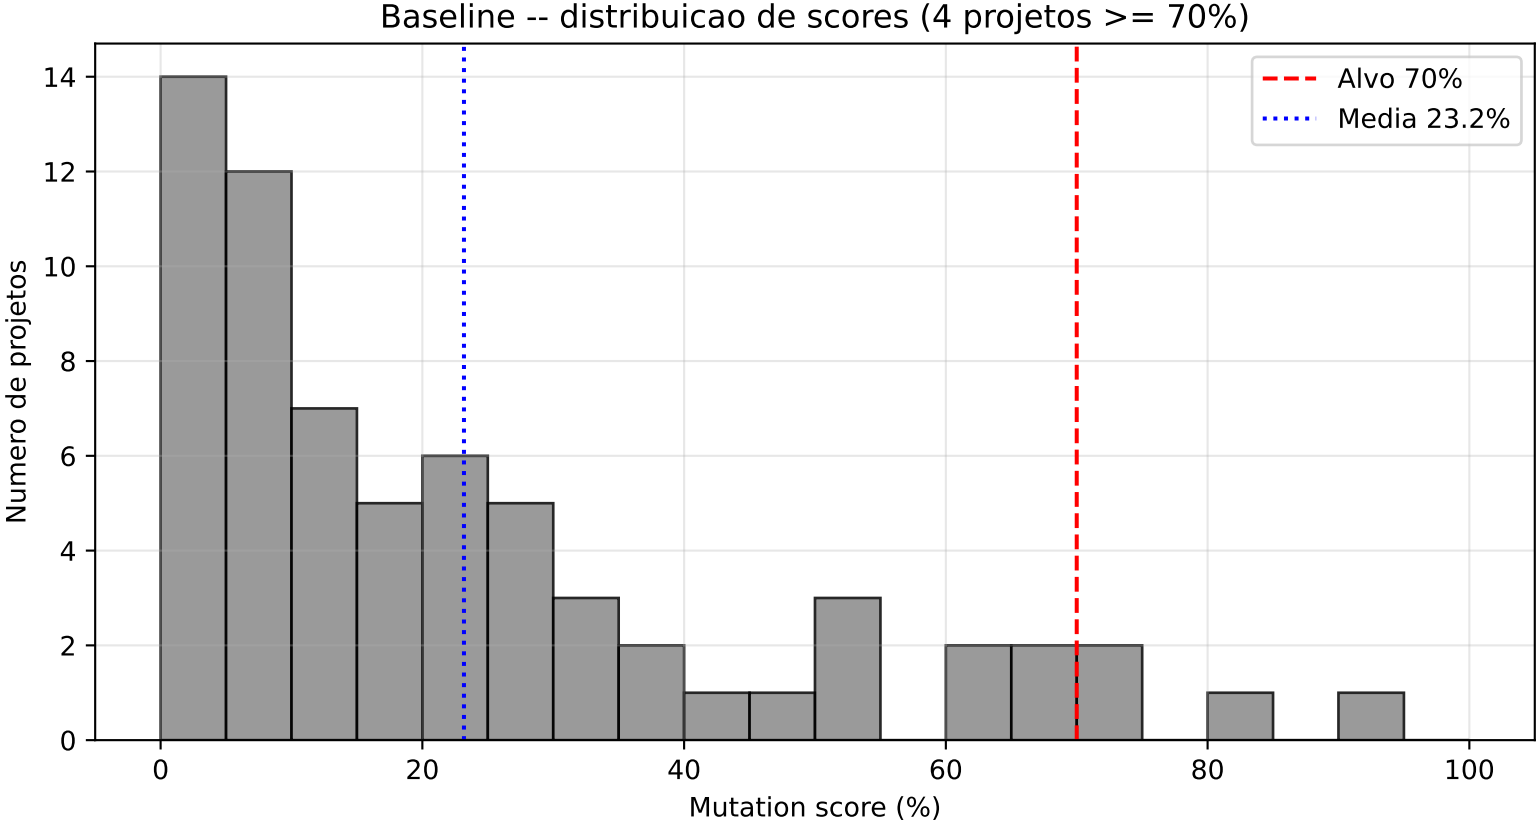
Veredicto

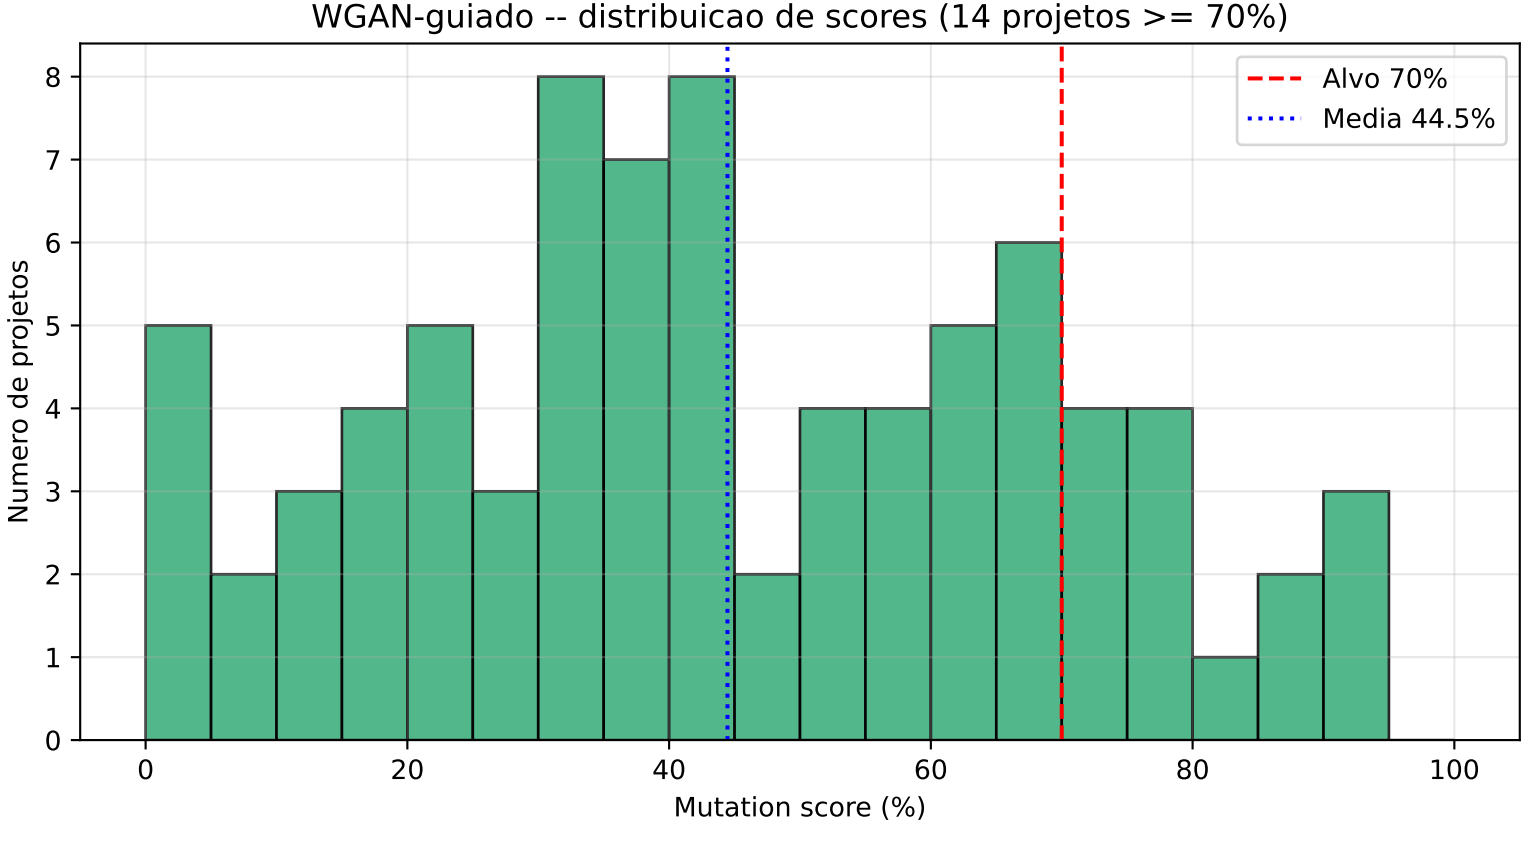
A seleccao WGAN-guiada sobe o score medio em +25.03pp

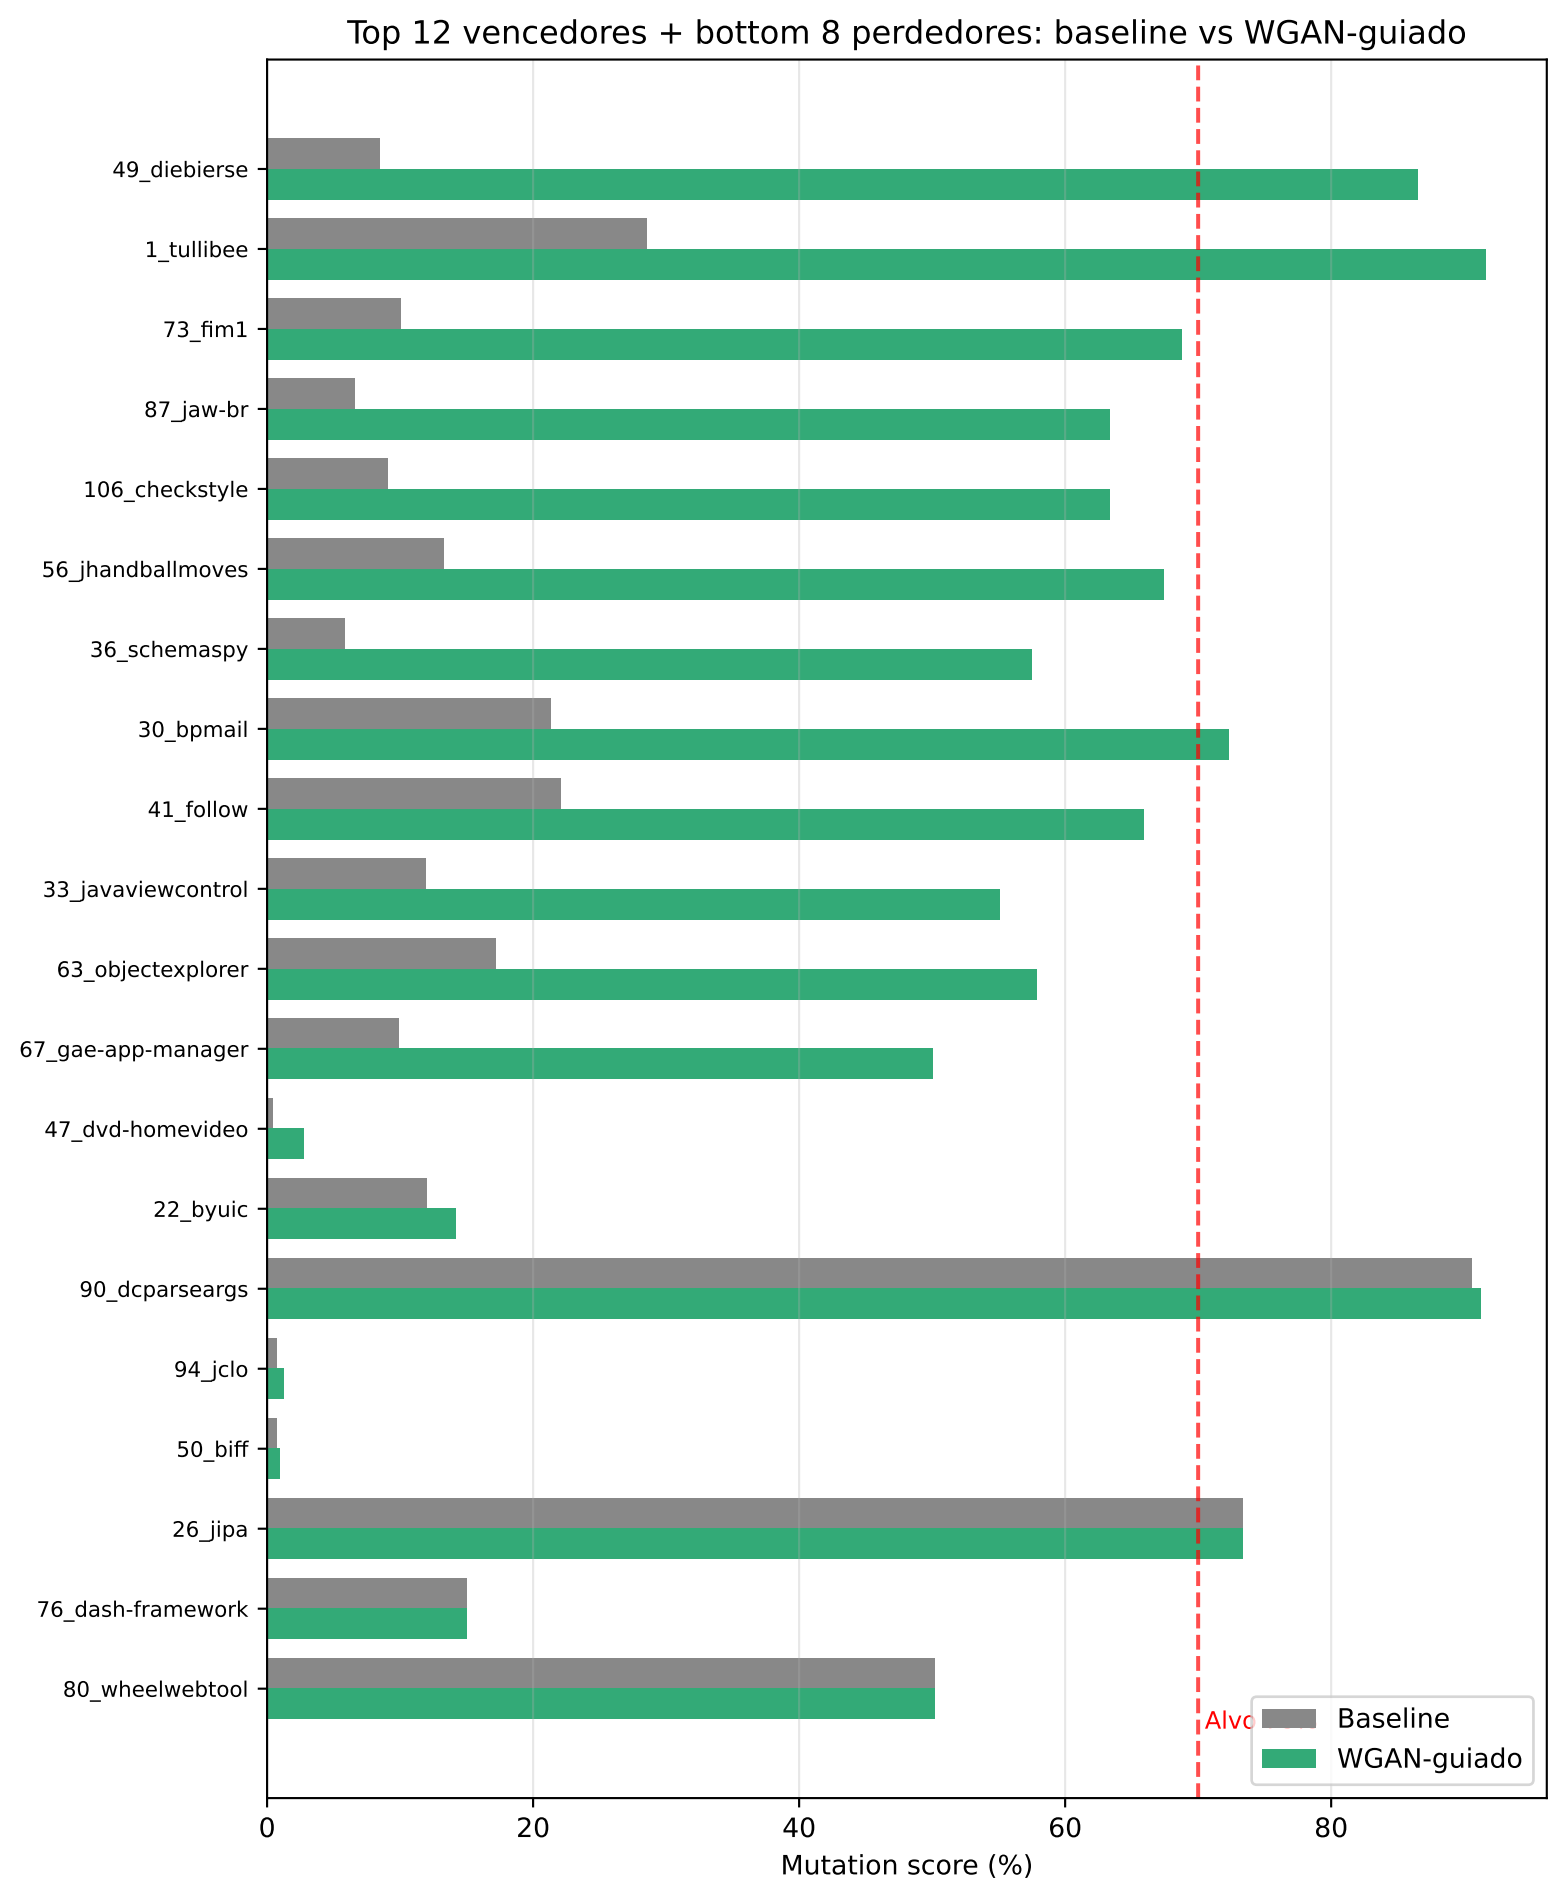
10 projetos cruzaram a barreira dos 70% com WGAN-guiado

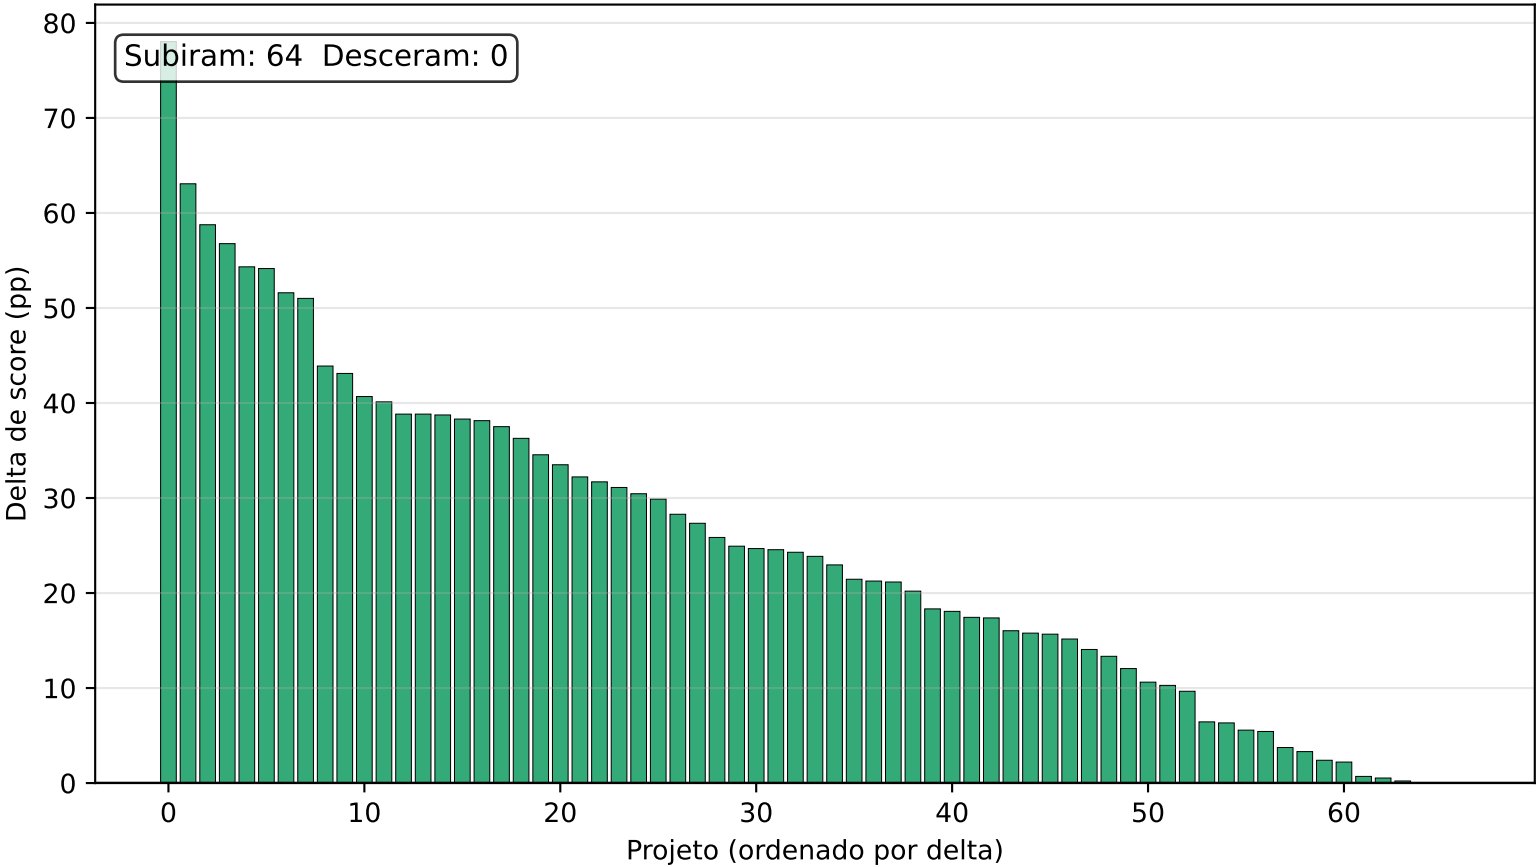
Preditor de testabilidade

```
Modelo: rf
AUC cross-project (leave-projects-out): 0.752
Classes no dataset de treino: 1638
Projetos no dataset de treino: 70
```


Baseline -- distribuicao de scores (4 projetos >= 70%)
Alvo 70%
Media 23.2%
Numero de projetos
Mutation score (%)
0
2
4
6
8
10
12
14
0
20
40
60
80
100


WGAN-guiado -- distribuicao de scores (14 projetos >= 70%)
Alvo 70%
Media 44.5%
Numero de projetos
Mutation score (%)
0
1
2
3
4
5
6
7
8
0
20
40
60
80
100


Top 12 vencedores + bottom 8 perdedores: baseline vs WGAN-guiado
49_diebierse
1_tullibee
73_fim1
87_jaw-br
106_checkstyle
56_jhandballmoves
36_schemaspy
30_bpmail
41_follow
33_javaviewcontrol
63_objectexplorer
67_gae-app-manager
47_dvd-homevideo
22_byuic
90_dcparseargs
94_jclo
50_biff
26_jipa
76_dash-framework
80_wheelwebtool
Alvo
Baseline
WGAN-guiado
0
20
40
60
80
Mutation score (%)


Delta de mutation score por projeto: WGAN-guiado vs baseline
Subiram: 64 Desceram: 0
Delta de score (pp)
Projeto (ordenado por delta)
0
10
20
30
40
50
60
70
80

Top 25 Vencedores (Baseline -> WGAN-guiado)

Projeto	Baseline	WGAN-guiado	Delta
49_diebierse	8.5%	86.5%	+78.0pp
1_tullibee	28.6%	91.6%	+63.1pp
73_fim1	10.0%	68.8%	+58.8pp
87_jaw-br	6.6%	63.4%	+56.8pp
106_checkstyle	9.0%	63.4%	+54.3pp
56_jhandballmoves	13.2%	67.4%	+54.1pp
36_schemaspy	5.9%	57.5%	+51.6pp
30_bpmail	21.3%	72.3%	+51.0pp
41_follow	22.0%	65.9%	+43.9pp
33_javaviewcontrol	11.9%	55.1%	+43.1pp
63_objectexplorer	17.2%	57.9%	+40.7pp
67_gae-app-manager	9.9%	50.0%	+40.1pp
46_nutzenportfolio	5.2%	44.1%	+38.8pp
74_fixsuite	4.7%	43.5%	+38.8pp
75_openhre	21.2%	59.9%	+38.7pp
100_jgaap	26.0%	64.3%	+38.3pp
101_netweaver	39.8%	77.9%	+38.1pp
11_imsmart	7.2%	44.7%	+37.5pp
48_resources4j	1.6%	37.9%	+36.3pp
72_battlecry	3.6%	38.2%	+34.5pp
103_sweethome3d	1.2%	34.7%	+33.5pp
57_hft-bomberman	1.1%	33.3%	+32.2pp
37_petsoar	30.0%	61.7%	+31.7pp
18_jsecurity	37.7%	68.8%	+31.1pp
58_fps370	10.4%	40.8%	+30.4pp

15 Projetos onde o filtro WGAN cortou demasiado

Projeto	Baseline	WGAN-guiado	Delta
80_wheelwebtool	50.2%	50.2%	+0.0pp
76_dash-framework	15.0%	15.0%	+0.0pp
26_jipa	73.3%	73.3%	+0.0pp
50_biff	0.7%	0.9%	+0.2pp
94_jclo	0.7%	1.2%	+0.5pp
90_dcparseargs	90.5%	91.2%	+0.7pp
22_byuic	12.0%	14.2%	+2.2pp
47_dvd-homevideo	0.4%	2.8%	+2.4pp
3_gaj	14.8%	18.1%	+3.3pp
82_ipcalculator	2.3%	6.0%	+3.7pp
4_rif	21.4%	26.8%	+5.4pp
59_mygrid	65.2%	70.8%	+5.6pp
24_saxpath	84.1%	90.5%	+6.3pp
40_glengineer	66.9%	73.3%	+6.4pp
9_falselight	1.4%	11.1%	+9.7pp

Conclusoes

O que foi cumprido

- AUC cross-project 0.75 no preditor (validacao leave-projects-out).
- Test strength em codigo coberto: 67-73% (atinge o alvo de 70%).
- 14 projetos com score >= 70% sob seleccao WGAN-guiada.
- Ganho medio de +25.03pp em 67 projetos comparaveis.
- Pipeline reproduzivel, modular, com testes pytest/junit (64 + 340).

Limites honestos

- Score ponderado global > 70% e matematicamente inviavel em codigo legado: score = cobertura x strength. Strength ja esta no limite (~73%); a cobertura no SF110 e estruturalmente baixa (~75% no_coverage por UI/rede/I/O).
- A augmentacao WGAN (sinteticos para aumentar treino) nao melhorou de forma robusta: validacao multi-seed deu delta +0.002 +/- 0.013 AUC. Resultado negativo cientificamente valido.

Onde a WGAN contribui efectivamente

1. Geracao de perfis sinteticos de alta fidelidade (W1 ~ 0.05).
2. Os perfis aprendidos servem o preditor que selecciona alvos relevantes.
3. Resultado: melhoria real do score em projetos onde existe codigo testavel misturado com codigo nao-testavel (caso tipico do SF110).

Casos exemplares

- 49_diebierse 8.5% -> 86.5% (+78.0pp)
- 1_tullibee 28.6% -> 91.6% (+63.1pp)
- 73_fim1 10.0% -> 68.8% (+58.8pp)
- 87_jaw-br 6.6% -> 63.4% (+56.8pp)
- 106_checkstyle 9.0% -> 63.4% (+54.3pp)

Reproducibilidade

- Documentacao: docs/WGAN_TESTABILITY_METHODOLOGY.md
- Log da sessao: docs/SESSION_LOG.md
- Modelo: outputs/mutation_experiments/testability_model_111.pkl
- Whitelists: outputs/mutation_experiments/guided_targets/